Instituto Tecnológico y de Estudios Superiores de Monterrey
Escuela de Ingeniería y Ciencias

Operaciones de aprendizaje automático (TC5061)
Gpo 10

Actividad colaborativa

Proyecto MiBici: propuesta y base reproducible

Equipo 10

Mariely Toribio Rodríguez	A01797848
Alan Augusto Herrera Sánchez	A01338336
Guillermo Sáenz González	A00823049
Victor Yoguel Salazar Alanis	A01797950

Fecha: 18 de octubre de 2026
Repositorio: github.com/WillSagzz/TC5061-Proyecto-Equipo10

Contenido

Introducción
- Enlace al repositorio

Formulación del problema
- P1. ¿Cuántos viajes se iniciarán en una estación o zona en un periodo futuro? (Regresión)
- P2. ¿Una estación estará en riesgo de quedarse sin bicicletas o sin anclajes disponibles en un periodo futuro? (Clasificación)
- P3. ¿Qué grupos de estaciones comparten patrones de uso y dónde se ubican en la ciudad? (Clustering)

ML Canvas
- Contenido del canvas por bloque

Definición de los datos y partición
- Rango de fechas propuesto
- Fuente de los archivos
- Tamaño real obtenido
- Variables originales
- Variables objetivo y cómo se construyen
- Condiciones de uso de MiBici y tratamiento de datos personales
- Estrategia de partición de los datos

Pipeline de ML
- Etapa 1: Ingesta, limpieza y homologación de datos
- Etapa 2: Agregaciones y construcción de la tabla base
- Etapa 3: Ingeniería de características
- Etapa 4: Partición de datos y entrenamiento de modelos
- Etapa 5: Evaluación y registro en MLflow Tracking
- Catálogo de variables a construir

Modelos y métricas
- P1: Predicción de demanda de viajes por estación y hora (Regresión)
- P2: Riesgo de estación vacía o sin anclajes disponibles (Clasificación)
- P3: Agrupación de estaciones por patrones de uso (Clustering)

Arquitectura del sistema
- Diagrama de arquitectura
- Componentes y herramientas

Experimento base en MLflow
- Diseño del experimento
- Comando de reproducción
- Resultados del experimento base
- Evidencia: capturas de la interfaz de MLflow

Repositorio del equipo
- Estructura del repositorio
- Buenas prácticas aplicadas
- Flujo de trabajo con Git/GitHub
- Integrantes y roles

Referencias

Introducción

Mi Bici es un Sistema de Bicicletas Públicas y transporte individual que presta servicio todos los días del año, basado en la renta de bicicletas disponibles en estaciones ubicadas en los puntos más importantes de las ciudades donde da cobertura. Inició en 2014 gracias a esfuerzos de colectivos ciclistas y dependencias gubernamentales que han promovido el uso de la bicicleta en las metrópolis. Actualmente el programa cuenta con 3,972 bicicletas y 360 estaciones en los municipios de Guadalajara, Zapopan y Tlaquepaque.

El propósito inicial de este entregable es traducir los retos operativos de MiBici, correspondiente al Área Metropolitana de Guadalajara, en tres problemas complementarios de *Machine Learning* (regresión, clasificación y *clustering*) que apoyen la toma de decisiones en la planificación de la flota, el rebalanceo de bicicletas y en la expansión del sistema.

Enlace al repositorio

https://github.com/WillSagzz/TC5061-Proyecto-Equipo10

Formulación del problema

Para cada pregunta de negocio se establece qué se predice o agrupa, su granularidad, el horizonte temporal y, en el caso de P2, la aproximación del riesgo ante la falta de datos de inventario en tiempo real. Con ello, cada formulación se vincula directamente con las decisiones del operador de flota, del equipo de rebalanceo y del área de planeación urbana.

P1. ¿Cuántos viajes se iniciarán en una estación o zona en un periodo futuro? (Regresión)

¿Qué se predice, con qué granularidad y horizonte? Se predice la cantidad total de viajes iniciados (salidas de bicicletas) como un valor numérico. La granularidad espacial es por estación individual y la granularidad temporal es de una hora. El horizonte de predicción es de 24 horas hacia adelante, pronosticando al cierre de cada día la demanda hora por hora del día siguiente.

¿Por qué es relevante para la operación de MiBici? Permite anticipar el volumen de actividad que tendrá cada punto de la red en el Área Metropolitana de Guadalajara, identificando con antelación las horas pico de saturación y las horas valle de baja actividad para dimensionar los recursos diarios del sistema sin interrumpir el servicio al ciudadano.

¿Quién usaría el resultado y qué decisión tomaría con él? El operador del sistema utilizaría estas predicciones para planear el tamaño de la flota activa de bicicletas que debe estar disponible en calle, programar las ventanas de mantenimiento preventivo de bicicletas y anclajes durante los horarios de menor demanda esperada, y organizar la asignación de turnos del personal operativo.

P2. ¿Una estación estará en riesgo de quedarse sin bicicletas o sin anclajes disponibles en un periodo futuro? (Clasificación)

¿Qué se predice, con qué granularidad y horizonte? Se predice una de tres categorías: *riesgo de vaciarse*, *riesgo de llenarse* o *sin riesgo*. La granularidad espacial es por estación individual y la granularidad temporal es de intervalos de 3 horas (8 intervalos por día; cada predicción habla de un bloque de 3 horas, por ejemplo: estación 25, intervalo de 9:00 a 12:00, clasificación: riesgo de vaciarse). El horizonte de predicción es de 3 horas hacia adelante: al cierre de cada intervalo se pronostica el riesgo de cada estación en el intervalo siguiente, usando solo los viajes ocurridos hasta ese momento. Así el equipo de rebalanceo puede intervenir la estación antes de que se vacíe o se llene.

> **Pendiente de decisión del equipo (texto en revisión en el Word original).** Existe una segunda versión de la formulación de P2 que debe conciliarse con la anterior, ya que el *pipeline*, el ML Canvas y la sección de modelos usan esta variante: "*Se predice una categoría binaria ("En riesgo" o "Sin riesgo") junto con su probabilidad de ocurrencia, indicando si una estación sufrirá desabasto de bicicletas o saturación total de sus espacios de anclaje. La granularidad espacial es por estación individual, la granularidad temporal es de una hora y el horizonte de predicción es de 1 a 3 horas hacia adelante, brindando el tiempo de anticipación necesario para que el personal operativo pueda trasladarse e intervenir la estación antes de que el problema ocurra.*" Hay que elegir una sola definición (tres clases en bloques de 3 h, o binaria por hora) y usarla de forma consistente en todo el documento y en `config.py`.

Definición y justificación de la aproximación del riesgo. Los datos de MiBici contienen el registro histórico de cada viaje y la capacidad total de anclajes de cada estación, pero no incluyen el inventario en tiempo real de cuántas bicicletas hay disponibles en cada minuto. Para resolver esta limitación de forma objetiva, el riesgo se aproxima midiendo la presión del flujo neto por intervalo en relación con el tamaño físico de cada estación:

- Para cada estación y en cada intervalo, se contabiliza el total de bicicletas que llegan (viajes que terminan ahí) y el total de bicicletas que salen (viajes que inician ahí).
- Se calcula la diferencia entre llegadas y salidas para obtener el desbalance neto de bicicletas en ese intervalo (cuántas bicicletas perdió o acumuló la estación sin compensarse por el flujo natural de los usuarios).
- Ese desbalance neto se compara contra la capacidad total de anclajes que tiene registrada la estación en el catálogo oficial.
- Cada intervalo se etiqueta en una de tres clases:
  - **Riesgo de vaciarse:** las salidas superan a las llegadas en al menos 40 % de la capacidad.
  - **Riesgo de llenarse:** las llegadas superan a las salidas en al menos 40 % de la capacidad.
  - **Sin riesgo:** la diferencia entre llegadas y salidas, sin importar si es positiva o negativa, es menor al 40 % de la capacidad.

- *Justificación metodológica:* este criterio es robusto porque evalúa la gravedad del flujo según el tamaño real de cada estación (perder 8 bicicletas en un intervalo es crítico para una estación pequeña de 12 anclajes, pero manejable para una estación grande de 40 anclajes) y evita adivinar cuántas bicicletas había al iniciar la mañana o arrastrar errores acumulados por movimientos de camionetas de rebalanceo que no están registrados en los datos abiertos.

¿Por qué es relevante para la operación de MiBici? Tanto una estación vacía (que impide a los usuarios iniciar un viaje) como una estación llena (que impide a los ciclistas devolver la bicicleta y cerrar su viaje en su destino) representan fallas directas en la disponibilidad del servicio público. Anticipar estos eventos permite pasar de una operación reactiva a una preventiva.

¿Quién usaría el resultado y qué decisión tomaría con él? El equipo de rebalanceo de bicicletas utilizaría las clasificaciones ordenadas por probabilidad de riesgo para decidir qué estaciones atender con prioridad y determinar cuántas bicicletas deben abastecer o retirar en cada punto.

P3. ¿Qué grupos de estaciones comparten patrones de uso y dónde se ubican en la ciudad? (Clustering)

¿Qué se agrupa, con qué granularidad y horizonte? Se agrupan las estaciones activas de la red en perfiles o *clusters* funcionales que comparten hábitos de uso similares. La agrupación se construye caracterizando a cada estación según qué porcentaje de sus viajes ocurre en cada intervalo del día (mañana, mediodía, tarde y noche), qué proporción de su demanda se concentra en días laborales frente a fines de semana, qué tanta rotación diaria tienen sus anclajes disponibles y si su balance habitual tiende a expulsar o a recibir viajes. La granularidad es por estación individual y el horizonte es estructural e histórico (consolidando el comportamiento típico de la estación durante todo el periodo de análisis). Una vez formados los grupos por su patrón de uso, se utilizan las coordenadas geográficas (latitud y longitud) del catálogo de estaciones para representar los *clusters* en el mapa de la ciudad y analizar su distribución territorial.

¿Por qué es relevante para la operación de MiBici? Permite descubrir la vocación real que tiene cada estación dentro de la movilidad del Área Metropolitana de Guadalajara (por ejemplo: distinguir estaciones residenciales de donde salen usuarios por la mañana, estaciones receptoras en zonas de oficinas o centros educativos, estaciones recreativas y estaciones periféricas de baja rotación).

¿Quién usaría el resultado y qué decisión tomaría con él? El área de planeación urbana y expansión del sistema utilizaría estos perfiles y su ubicación en el mapa para decidir en qué zonas de la ciudad instalar nuevas estaciones, identificar qué estaciones existentes requieren una ampliación física de anclajes por alta rotación estructural, y diseñar políticas de interconexión con otras redes de transporte público o ciclovías.

ML Canvas

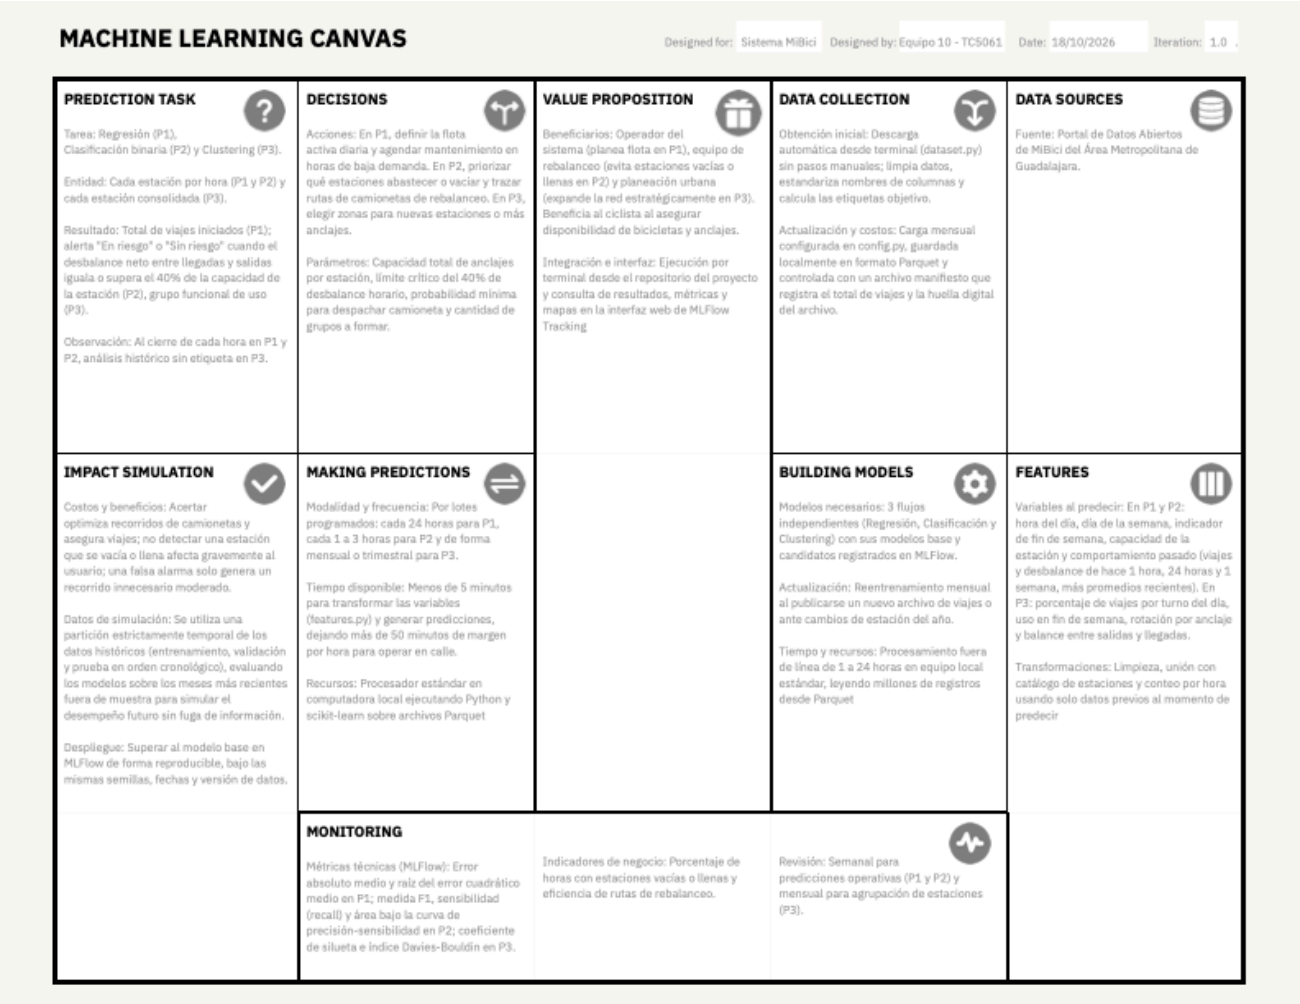


Figura 1. ML Canvas del proyecto MiBici (Equipo 10).

> **TODO.** Reemplazar `references/ml_canvas.png` por la versión final del canvas en alta resolución y transcribir el contenido de cada bloque en las subsecciones siguientes.

Contenido del canvas por bloque

Propuesta de valor (Value proposition)

TODO

Decisiones (Decisions)

TODO

Tarea de predicción (Prediction task)

TODO

Simulación de impacto (Impact simulation)

TODO

Generación de predicciones (Making predictions)

TODO

Fuentes de datos (Data sources)

TODO

Recolección de datos (Data collection)

TODO

Variables (Features)

TODO

Construcción de modelos (Building models)

TODO

Monitoreo (Monitoring)

TODO

Definición de los datos y partición

Rango de fechas propuesto

Los datos de MiBici abarcan desde diciembre de 2014 hasta septiembre de 2026. Sin embargo, usar todo el historial no garantiza mejores resultados. Los hábitos de movilidad cambian con el tiempo: cambia el comportamiento ciudadano, se abren estaciones nuevas, cambia la capacidad de otras, se modifican vías y carreteras, etc. Por eso, los patrones de hace varios años pueden no representar el comportamiento actual de nuestro intervalo de estudio. Además, los años 2020 y 2021 están alterados por la pandemia e introducen patrones anómalos. Por estas razones se selecciona un periodo de estudio acotado: el rango escogido es el más reciente, correspondiente a los últimos 24 meses, desde **septiembre de 2024 hasta agosto de 2026**. Esto permite capturar patrones estacionales de datos actuales, con los que estamos más familiarizados, y evitar utilizar estaciones que hayan desaparecido.

Fuente de los archivos

El portal donde se alojan los datos de MiBici es https://mibici.net/es/datos-abiertos/. Los viajes se publican mensualmente; la Tabla 1 lista los 24 archivos que se utilizarán. Además se utiliza el catálogo de estaciones (nomenclatura) alojado en https://www.mibici.net/site/assets/files/1118/nomenclatura_2026_09.csv.

Tabla 1. Archivos mensuales de viajes utilizados en el proyecto.

Mes	Archivo
2024-09	https://www.mibici.net/site/assets/files/89736/datos_abiertos_2024_09.csv
2024-10	https://www.mibici.net/site/assets/files/91758/datos_abiertos_2024_10.csv
2024-11	https://www.mibici.net/site/assets/files/93516/datos_abiertos_2024_11.csv
2024-12	https://www.mibici.net/site/assets/files/94962/datos_abiertos_2024_12.csv
2025-01	https://www.mibici.net/site/assets/files/97653/datos_abiertos_2025_01.csv
2025-02	https://www.mibici.net/site/assets/files/99879/datos_abiertos_2025_02.csv
2025-03	https://www.mibici.net/site/assets/files/101986/datos_abiertos_2025_03.csv
2025-04	https://www.mibici.net/site/assets/files/103813/datos_abiertos_2025_04.csv
2025-05	https://www.mibici.net/site/assets/files/105513/datos_abiertos_2025_05.csv
2025-06	https://www.mibici.net/site/assets/files/107088/datos_abiertos_2025_06.csv
2025-07	https://www.mibici.net/site/assets/files/108898/datos_abiertos_2025_07.csv
2025-08	https://www.mibici.net/site/assets/files/111021/datos_abiertos_2025_08.csv

Mes	Archivo
2025-09	https://www.mibici.net/site/assets/files/113216/datos_abiertos_2025_09.csv
2025-10	https://www.mibici.net/site/assets/files/115104/datos_abiertos_2025_10.csv
2025-11	https://www.mibici.net/site/assets/files/116773/datos_abiertos_2025_11.csv
2025-12	https://www.mibici.net/site/assets/files/118153/datos_abiertos_2025_12.csv
2026-01	https://www.mibici.net/site/assets/files/120163/datos_abiertos_2026_01.csv
2026-02	https://www.mibici.net/site/assets/files/121761/datos_abiertos_2026_02.csv
2026-03	https://www.mibici.net/site/assets/files/123236/datos_abiertos_2026_03.csv
2026-04	https://www.mibici.net/site/assets/files/124927/datos_abiertos_2026_04.csv
2026-05	https://www.mibici.net/site/assets/files/125943/datos_abiertos_2026_05.csv
2026-06	https://www.mibici.net/site/assets/files/127734/datos_abiertos_2026_06.csv
2026-07	https://www.mibici.net/site/assets/files/129006/datos_abiertos_2026_07.csv
2026-08	https://www.mibici.net/site/assets/files/130362/datos_abiertos_2026_08.csv

Tamaño real obtenido

- **Meses.** El conjunto consolidado comprende la totalidad de los 24 meses analizados, del 1 de septiembre de 2024 al 31 de agosto de 2026.
- **Número de viajes.** Durante este periodo se registró un volumen acumulado de **8,943,941 viajes**, con un promedio de 372,664 viajes mensuales.
- **Número de estaciones.** En el catálogo oficial de estaciones (nomenclatura) se identificaron **484** estaciones; sin embargo, en el periodo estudiado solo **472** estaciones registran actividad. Al cruzar ambas fuentes:
  - De las 472 estaciones con actividad, **470** están en la nomenclatura.
  - Las **2** estaciones que registran viajes pero no están en la nomenclatura son los ID **405** y **407**. Al no contar con información sobre ellas (capacidad y coordenadas), sus registros se excluyen del proyecto en la etapa de limpieza.
  - **14** estaciones están en la nomenclatura pero no tienen registro de viajes en el periodo estudiado.

Variables originales

Tabla 2. Variables originales de los archivos de MiBici que se utilizan en el proyecto.

Variable original	Archivo	Uso
`Viaje_Id`	`datos_abiertos_AAAA_MM.csv`	Detección de registros duplicados.

Variable original	Archivo	Uso
`Inicio_del_viaje`	`datos_abiertos_AAAA_MM.csv`	Fecha y hora de inicio del viaje.
`Fin_del_viaje`	`datos_abiertos_AAAA_MM.csv`	Fecha y hora de fin del viaje.
`Origen_Id`	`datos_abiertos_AAAA_MM.csv`	Estación de la que sale la bicicleta (inicio del viaje).
`Destino_Id`	`datos_abiertos_AAAA_MM.csv`	Estación a la que llega la bicicleta (fin del viaje).
`id`	`nomenclatura_2026_09.csv`	Asocia el número de `Origen_Id` y `Destino_Id` con su nombre de la nomenclatura o `name` (GDL-001).
`name`	`nomenclatura_2026_09.csv`	Indica el municipio.
`latitude`, `longitude`	`nomenclatura_2026_09.csv`	Localizar las estaciones en el mapa.
`dpcapacity`	`nomenclatura_2026_09.csv`	Capacidad de anclajes de cada estación.

Variables objetivo y cómo se construyen

Tabla 3. Construcción de la variable objetivo de cada pregunta.

Pregunta	Variable objetivo	Construcción
P1. Regresión. ¿Cuántos viajes se iniciarán en una estación o zona en un periodo futuro?	Viajes iniciados (entero).	Sumatoria de los viajes iniciados en cada estación durante cada hora. La hora de inicio de cada viaje se redondea hacia abajo a la hora completa (por ejemplo, 08:47 pasa a 08:00) y se agrupan los viajes por estación de origen y hora. Las combinaciones de estación y hora sin viajes se registran como cero.
P2. Clasificación. ¿Una estación estará en riesgo de quedarse sin bicicletas o sin anclajes disponibles en un periodo futuro?	Riesgo (categórica) con tres clases: riesgo de vaciarse, riesgo de llenarse, sin riesgo.	El día se divide en 8 intervalos de 3 horas y cada viaje se asigna dos veces: como salida de su estación de origen y como llegada de su estación de destino, cada una en el intervalo que corresponda. Se suman las salidas y las llegadas de cada estación en cada intervalo y se calcula el flujo neto (llegadas menos salidas); las combinaciones sin viajes se registran como cero. El flujo neto se compara con el 40 % de la capacidad de la estación: (1) *riesgo de vaciarse* si el flujo es menor o igual a −40 % de la capacidad; (2) *riesgo de llenarse* si es mayor o igual a +40 %; (3) *sin riesgo* si está estrictamente entre ambos umbrales.
P3. Clustering. ¿Qué grupos de estaciones comparten patrones de uso y dónde se ubican en la ciudad?	No posee una variable objetivo.	

Condiciones de uso de MiBici y tratamiento de datos personales

Los datos se obtienen del portal de datos abiertos de MiBici, sistema administrado por la **Agencia Metropolitana de Servicios de Infraestructura para la Movilidad del Área Metropolitana de Guadalajara (AMIM)**. El portal no publica una licencia para los archivos. Sin embargo, el Reglamento Interno en materia de Transparencia de la AMIM establece que la Agencia gestiona su información bajo una política de datos abiertos que favorece la creación de conocimiento (art. 6, fr. IV), y que la información que genera es pública y de libre acceso, salvo la reservada o confidencial (art. 18). Con base en ello, los datos se usarán solo con fines académicos, no se redistribuirán y no se utilizarán directa o indirectamente para intentar identificar usuarios.

El mismo reglamento considera confidencial la información con datos personales de una persona identificada o identificable (art. 21). Los archivos de viajes incluyen los campos `Usuario_Id`, `Genero` y `Año_de_nacimiento` que, combinados con los horarios y estaciones de cada viaje, podrían permitir identificar a una persona. Como las preguntas de negocio no requieren esta información, su uso será descartado del proyecto.

Estrategia de partición de los datos

La partición no puede ser aleatoria porque trabajamos con variables temporales: una partición al azar puede producir un entrenamiento sin representatividad de días o estaciones o, en el peor de los casos, entrenar con datos futuros e introducir fuga de información. Las prácticas que se aplican en el proyecto para evitar estos escenarios son:

- Utilizar variables construidas únicamente con datos disponibles antes del momento de la predicción. Si un modelo tiene como horizonte el día siguiente, solo se usan datos anteriores a esa fecha.
- Se utilizarán tres particiones para los conjuntos de entrenamiento, validación y prueba, cada una de ellas con fechas específicas de división, que serán establecidas en `config.py`.
- Las transformaciones sólo serán ajustadas con el conjunto de entrenamiento y se aplicarán, sin recalcular, a los conjuntos de validación y prueba.

TODO: definir las fechas específicas de división de cada conjunto en `config.py`.

Pipeline de ML

El diseño del *pipeline* de *Machine Learning* establece la secuencia de procesamiento que transforma los registros crudos de viajes y el catálogo de estaciones de MiBici en datos estructurados listos para entrenar y evaluar los modelos de regresión (P1), clasificación (P2) y *clustering* (P3). Para optimizar el desarrollo, las preguntas P1 y P2 comparten una misma base de procesamiento horario por estación, mientras que P3 consolida el comportamiento histórico a nivel de estación única. Todas las transformaciones se diseñan bajo el principio de estricto corte temporal, garantizando que ninguna variable utilice información posterior al momento de la predicción.

Etapa 1: Ingesta, limpieza y homologación de datos

Esta etapa inicial es común para P1, P2 y P3 y se ejecuta de manera automatizada en el archivo `dataset.py` a partir de los archivos mensuales de viajes y el catálogo de estaciones:

- **Homologación:** estandarización de los nombres de columnas y corrección de la codificación de caracteres entre los distintos archivos mensuales, además de la conversión de las fechas de inicio y fin de viaje a un formato de tiempo uniforme.
- **Depuración:** eliminación de registros duplicados, viajes sin estación de origen o destino identificada, viajes con fechas inconsistentes y viajes atípicos que no representan traslados reales.
- **Cruce con catálogo de estaciones:** unión de los viajes limpios con el archivo de nomenclatura para incorporar la capacidad total de anclajes y las coordenadas geográficas (latitud y longitud), descartando registros asociados a estaciones dadas de baja o inexistentes en el catálogo oficial.
- **Almacenamiento:** guardado de la tabla limpia en formato Parquet y registro de su versión mediante un archivo manifiesto con conteo de filas y código identificador único.

Etapa 2: Agregaciones y construcción de la tabla base

A partir de los viajes limpios, los datos se agrupan según la unidad de análisis de cada pregunta.

Para P1 y P2 (nivel estación y hora):

- Se agrupan los viajes por estación de origen y ventana de una hora para obtener el total de salidas por hora.
- Se agrupan los viajes por estación de destino y ventana de una hora para obtener el total de llegadas por hora.
- Se genera una malla completa de todas las estaciones activas por todas las horas del periodo de estudio, rellenando con cero aquellas horas en las que una estación no tuvo salidas o llegadas, asegurando así series de tiempo continuas sin huecos.
- **Construcción de variables objetivo:** para P1, la variable a predecir es el conteo de salidas registradas en la hora futura correspondiente. Para P2, se calcula la diferencia neta entre llegadas

y salidas en esa hora futura, se compara contra la capacidad total de anclajes de la estación y se asigna la etiqueta binaria "En riesgo" cuando dicho desbalance iguala o supera el 40 % de su capacidad, o "Sin riesgo" en caso contrario.

Para P3 (nivel estación única):

- Utilizando únicamente el periodo histórico de entrenamiento, se agrupan todos los viajes por estación para resumir su volumen total de salidas, su volumen de llegadas y su distribución porcentual a lo largo de las horas del día y los días de la semana.
- Como es una tarea no supervisada, se construye una matriz donde cada fila representa una estación única caracterizada por sus hábitos de uso.

Etapa 3: Ingeniería de características

En esta etapa se calculan las variables predictoras mediante funciones reutilizables y documentadas dentro del módulo `features.py`:

- **Para P1 y P2:** se generan variables de calendario (hora, día, fin de semana), rezagos históricos (comportamiento de la estación horas o días antes) y promedios móviles recientes. Para evitar fuga de información del futuro (*data leakage*), toda variable histórica se calcula exclusivamente con datos cerrados antes de la hora en que se emite la predicción.
- **Para P3:** se calculan proporciones relativas de uso por franja horaria, rotación por anclaje y balance entre salidas y llegadas. Posteriormente, todas las variables numéricas de P3 se estandarizan a una misma escala para evitar que las estaciones más grandes dominen el algoritmo de agrupación por simple volumen de viajes.

Etapa 4: Partición de datos y entrenamiento de modelos

- **Para P1 y P2:** no se utiliza partición aleatoria, sino un corte estrictamente cronológico (los primeros meses del periodo para entrenamiento, un bloque intermedio para validación y el bloque más reciente para prueba), garantizando que el modelo siempre aprenda del pasado para predecir el futuro. En P2, adicionalmente, se contempla el manejo del desbalance de clases durante el entrenamiento, dado que las horas críticas son menos frecuentes que las horas de operación normal.
- **Para P3:** se entrena el algoritmo de agrupación sobre el perfil consolidado de las estaciones, evaluando distintos números de grupos para encontrar una segmentación interpretable.

Etapa 5: Evaluación y registro en MLflow Tracking

- Los modelos base y candidatos se ejecutan desde el código del repositorio y se evalúan sobre el conjunto de prueba temporal (en P1 y P2) o mediante métricas de cohesión interna y proyección en el mapa de Guadalajara (en P3).

- Cada ejecución registra automáticamente en MLflow Tracking los parámetros de reproducción (rango de fechas, versión de datos, semilla aleatoria e hiperparámetros).

Catálogo de variables a construir

Tabla 5. Variables para P1 y P2.

Variable	Descripción	Objetivo en MiBici
Hora del día	Transformación de la hora (0 a 23).	La movilidad urbana sigue ciclos diarios muy marcados (horas pico de entrada/salida laboral y escolar frente a madrugadas sin actividad).
Día de la semana e indicador de fin de semana	Número del día de la semana (lunes a domingo) y variable binaria que distingue sábado y domingo de los días laborales.	El patrón de viajes cambia drásticamente entre días de oficina y fines de semana.
Salidas registradas 1 h, 24 h y 7 días antes	Cantidad de viajes que iniciaron en esa misma estación exactamente 1 hora antes, el día anterior a la misma hora y la semana anterior a la misma hora.	Es el predictor directo más fuerte del volumen de viajes: captura la inercia inmediata de la estación y su hábito semanal.
Promedio móvil de 3 h	Promedio de viajes iniciados en la estación durante las 3 horas cerradas previas al momento de predicción.	Suaviza variaciones bruscas de una sola hora y refleja si la demanda de la estación está acelerándose o desacelerándose en ese turno.
Llegadas y desbalance neto (1 h y 24 h antes)	Cantidad de bicicletas que llegaron y diferencia neta entre llegadas y salidas en esa estación 1 hora antes y 24 horas antes.	Permite detectar si la estación ya viene sufriendo una pérdida o acumulación rápida de bicicletas en la hora inmediata anterior, o si suele saturarse a esa hora del día.
Capacidad total de anclajes	Número total de espacios físicos instalados en la estación según el catálogo oficial de nomenclatura.	En P1 acota el volumen máximo que puede despachar una estación y en P2 determina qué tan sensible es la estación a quedarse vacía o llena ante pocos viajes.

Tabla 6. Variables para P3.

Variable	Descripción	Objetivo en MiBici
Proporción de viajes por franja del día y en fin de semana	Porcentaje del total de viajes de la estación que ocurre en el bloque matutino (6-10 h), mediodía (10-14 h), vespertino (14-19 h) y nocturno (19-6 h).	Permite agrupar estaciones con ritmos horarios similares independientemente de si son estaciones grandes o pequeñas en volumen total.
Índice de atracción y emisión de viajes matutinos	Proporción de salidas frente al total de movimientos (salidas más llegadas) de la estación durante las horas pico de la mañana.	Identifica el rol funcional de la estación en la ciudad y puede ayudar a distinguir zonas habitacionales de zonas de oficinas.

Variable	Descripción	Objetivo en MiBici
Tasa de rotación diaria por anclaje	Promedio de viajes diarios atendidos por la estación dividido entre su número total de anclajes instalados.	Mide el nivel de presión física de la infraestructura: detecta estaciones pequeñas con altísima demanda que requieren ampliación prioritaria de anclajes por parte de planeación urbana.
Latitud y longitud	Coordenadas geográficas de cada estación.	No se introducen al algoritmo para no forzar grupos por simple cercanía de calles, sino que se usan al final para proyectar los grupos en el mapa de Guadalajara.

Modelos y métricas

Para evaluar la viabilidad técnica se establece una estrategia de modelado incremental para cada pregunta de negocio. En primer lugar, se define un modelo base (*baseline*) de baja complejidad que se ejecuta y registra en MLflow Tracking como punto de referencia mínimo. Posteriormente, se proponen modelos candidatos con mayor capacidad para capturar relaciones no lineales en los datos. Finalmente, se seleccionan métricas de evaluación de la librería scikit-learn alineadas tanto con la estructura técnica de cada problema como con el impacto operativo de las decisiones en MiBici.

P1: Predicción de demanda de viajes por estación y hora (Regresión)

Modelo baseline

Ridge: modelo lineal sencillo que estima el número de viajes que iniciarán en la siguiente hora a partir de los rezagos básicos de demanda (viajes hace 1 hora, hace 24 horas y hace 7 días) y la hora del día. Se elige como *baseline* porque es rápido de entrenar sobre millones de registros, requiere un ajuste mínimo de hiperparámetros y ofrece una línea base interpretable que supera a un simple promedio estático al incorporar la inercia reciente de cada estación.

Modelos candidatos

- **HistGradientBoostingRegressor o LightGBM:** algoritmo de árboles de decisión ensamblados de forma secuencial, diseñado específicamente para grandes volúmenes de datos tabulares. Es ideal para P1 porque maneja de forma nativa relaciones no lineales complejas (por ejemplo, el efecto combinado de ser viernes por la tarde en una estación de alta capacidad) y procesa millones de filas en pocos segundos.
- **RandomForestRegressor:** ensamble de múltiples árboles independientes que reduce la varianza de las predicciones y es robusto frente a valores atípicos en horas de demanda inusual.

Métricas de evaluación

- **Error absoluto medio (`mean_absolute_error`):** mide el promedio de la diferencia absoluta entre los viajes reales y los predichos. Se expresa en las mismas unidades del negocio (viajes o bicicletas por hora), lo que permite al operador interpretar directamente cuántas bicicletas de desviación promedio tiene el pronóstico al dimensionar la flota activa diaria y planear ventanas de mantenimiento. Además, no se distorsiona de forma exagerada por un día atípico (como un evento masivo en la ciudad).
- **Raíz del error cuadrático medio (`root_mean_squared_error`):** mide la magnitud del error dando un peso mucho mayor a las desviaciones grandes. En la operación de MiBici, equivocarse por 1 bicicleta durante 10 horas seguidas es manejable, pero equivocarse por 15 bicicletas en una sola

hora pico provoca el colapso inmediato de la estación. Esta métrica penaliza severamente a los modelos que fallan por márgenes amplios en las horas de mayor demanda.

P2: Riesgo de estación vacía o sin anclajes disponibles (Clasificación)

Modelo baseline

LogisticRegression: clasificador lineal que estima la probabilidad de que una estación entre en estado crítico. Con `class_weight="balanced"` se corrige la desproporción entre horas normales y horas críticas; es rápida de entrenar y entrega probabilidades calibradas, necesarias para ordenar las estaciones por urgencia de atención.

Modelos candidatos

- **HistGradientBoostingClassifier o XGBoost:** capaz de detectar umbrales abruptos donde la combinación de pérdidas acumuladas en las últimas 3 horas, la hora pico y una capacidad reducida de anclajes disparan el riesgo de vaciado o saturación.
- **RandomForestClassifier:** con `class_weight="balanced_subsample"` permite capturar interacciones complejas entre variables temporales y físicas de la estación, manteniendo estabilidad ante el desbalance de clases.

Métricas de evaluación

- **Sensibilidad o exhaustividad (`recall_score`):** del total de estaciones que realmente sufrieron un desbalance crítico, qué porcentaje logró detectar el modelo con anticipación. Para el equipo de rebalanceo, el error más costoso es el falso negativo (no enterarse de que una estación se iba a quedar sin bicicletas o sin anclajes libres, dejando a los usuarios sin servicio). Priorizar una alta sensibilidad asegura que la gran mayoría de las emergencias reales sean detectadas a tiempo.
- **F1 (`f1_score`):** equilibrio armónico entre la sensibilidad (detectar los riesgos reales) y la precisión (que las alertas emitidas sean verdaderas). Si el modelo alertara riesgo en todas las estaciones para no fallar ninguna, las camionetas de rebalanceo harían viajes innecesarios gastando combustible y tiempo. El puntaje F1 evalúa que el modelo detecte las estaciones críticas sin saturar al equipo operativo con falsas alarmas.

P3: Agrupación de estaciones por patrones de uso (Clustering)

Modelo baseline

KMeans: algoritmo que agrupa las estaciones en un número predefinido de perfiles (evaluando inicialmente entre 4 y 5 grupos funcionales) minimizando la variación interna de los hábitos de uso estandarizados. Es el estándar de referencia en segmentación no supervisada, converge rápidamente y genera centros de grupo fáciles de interpretar como perfiles urbanos (residencial, oficinas, recreativo, baja demanda).

Modelos candidatos

- **AgglomerativeClustering:** construye una jerarquía de grupos de abajo hacia arriba sin depender de una inicialización aleatoria de centros. Permite a planeación urbana visualizar mediante un dendrograma cómo se relacionan las estaciones a distintas escalas.
- **GaussianMixture:** a diferencia de K-Means, permite formar grupos de distinta dispersión y asigna a cada estación un grado de pertenencia probabilística a cada perfil funcional (útil para estaciones de uso mixto comercial-habitacional).

Métricas de evaluación

- **Coeficiente de silueta (`silhouette_score`):** mide qué tan parecidas son las estaciones dentro de un mismo grupo en comparación con las estaciones de los grupos vecinos. Garantiza al área de planeación urbana y expansión que las categorías de estaciones descubiertas tienen hábitos de movilidad internamente consistentes y claramente diferenciados entre sí antes de usarlos para diseñar políticas de infraestructura por zona.
- **Índice de Davies-Bouldin (`davies_bouldin_score`):** mide la relación promedio entre la dispersión interna de cada grupo y la distancia que separa a los distintos grupos entre sí. Funciona como criterio objetivo de desempate para elegir el número óptimo de grupos de estaciones en Guadalajara, evitando crear demasiados perfiles redundantes que dificulten la toma de decisiones territoriales.

Arquitectura del sistema

> **TODO.** Esta sección no existe aún en el documento original. La actividad pide (paso 5): un diagrama que muestre los componentes de la solución y cómo se conectan (fuentes de datos, ingesta, almacenamiento, procesamiento, entrenamiento y registro de experimentos), declarar las herramientas de cada componente y justificar su elección de acuerdo con las lecturas de la semana. El diagrama debe guardarse también en `references/`.

Diagrama de arquitectura

TODO

Componentes y herramientas

TODO

Experimento base en MLflow

> **TODO.** Esta sección no existe aún en el documento original. La actividad pide (pasos 6 y 7): resultados del experimento base con al menos un *run* por pregunta (parámetros de reproducción, métricas, etiquetas y artefactos), el comando documentado para reproducirlo y las cuatro capturas de la interfaz de MLflow.

Diseño del experimento

TODO

Comando de reproducción

TODO

Resultados del experimento base

TODO

Evidencia: capturas de la interfaz de MLflow

TODO: guardar las capturas en `figuras/` y descomentar las figuras siguientes.

Repositorio del equipo

> **TODO.** Esta sección no existe aún en el documento original. La tabla de entregables pide incluir en el PDF una captura de la estructura del repositorio; el resto de los apartados (buenas prácticas, flujo de trabajo con Git, integrantes y roles) se documentan en el README y pueden resumirse aquí.

Repositorio: https://github.com/WillSagzz/TC5061-Proyecto-Equipo10

Estructura del repositorio

TODO: insertar la captura de la estructura del repositorio en GitHub (`figuras/repositorio_estructura.png`).

Buenas prácticas aplicadas

TODO

Flujo de trabajo con Git/GitHub

TODO

Integrantes y roles

TODO

Referencias

> **TODO.** Esta sección no existe aún en el documento original. Listar en formato APA 7 todas las fuentes citadas en el texto (MiBici, reglamento de transparencia de la AMIM, MLflow, scikit-learn, Cookiecutter Data Science, lecturas del curso, etc.).

TODO