MACHINE LEARNING CANVAS

Designed for: Sistema MiBici | Designed by: Equipo 10 - TC5061 | Date: 18/10/2026 | Iteration: 1.1

PREDICTION TASK

Tarea: regresión (P1), clasificación multiclase con tres clases (P2) y clustering (P3).

Entidad: cada estación en cada hora (P1), cada estación en cada intervalo de 3 horas (P2) y cada estación consolidada en todo el periodo (P3).

Resultado: total de viajes iniciados en la hora (P1); clase *riesgo de vaciarse*, *riesgo de llenarse* o *sin riesgo*, según el flujo neto de llegadas menos salidas alcance −40 %, +40 % o quede entre ambos umbrales de la capacidad de la estación (P2); grupo funcional de uso (P3).

Observación: al cierre de cada día se predicen las 24 horas del día siguiente (P1); al cierre de cada intervalo se predice el siguiente (P2); análisis histórico sin etiqueta (P3).

DECISIONS

Acciones: en P1, dimensionar la flota activa del día siguiente y agendar el mantenimiento en horas de baja demanda. En P2, priorizar qué estaciones abastecer o vaciar en el siguiente intervalo de 3 horas y trazar la ruta de las camionetas de rebalanceo. En P3, elegir zonas para estaciones nuevas y estaciones que requieren más anclajes.

Parámetros: capacidad de anclajes de cada estación, umbral del 40 % de la capacidad y longitud del intervalo (3 h) de P2, probabilidad mínima para despachar una camioneta y número de grupos en P3. Todos viven en config.py.

VALUE PROPOSITION

Beneficiarios: el operador del sistema, que planea la flota activa con P1; el equipo de rebalanceo, que evita estaciones vacías o llenas con P2; y el área de planeación urbana, que expande la red con P3. El beneficiario final es el ciclista, que encuentra bicicletas para salir y anclajes para llegar.

Integración e interfaz: predicciones por lotes desde la terminal con el código del repositorio (make data, make features, make train); resultados, métricas y mapas consultados en la interfaz web de MLflow Tracking, en modo local en esta entrega.

DATA COLLECTION

Obtención inicial: descarga automática desde la terminal con dataset.py, sin pasos manuales: descubre los enlaces en el portal, descarga los archivos del periodo, normaliza columnas, codificación y fechas, elimina duplicados y datos personales y guarda Parquet.

Actualización y costos: MiBici publica un archivo nuevo cada mes; el rango de fechas se controla en config.py y la versión de los datos queda en un manifiesto con el número de registros y el hash de cada archivo. El costo es solo el tiempo de descarga.

DATA SOURCES

Fuente: portal de datos abiertos de MiBici (administrado por la AMIM): un CSV por mes con los viajes y un archivo de nomenclatura con identificador, nombre, coordenadas y capacidad de cada estación.

Periodo: 24 meses, de septiembre de 2024 a agosto de 2026; 8,943,941 viajes y 484 estaciones en el catálogo.

IMPACT SIMULATION

Costos y beneficios: acertar en P1 y P2 optimiza los recorridos de las camionetas y asegura que los viajes puedan iniciarse y terminarse; no detectar una estación que se vacía o se llena afecta directamente al usuario, mientras que una falsa alarma solo cuesta un recorrido innecesario. En P2 se privilegia la sensibilidad sobre la precisión.

Datos de simulación: partición estrictamente cronológica (entrenamiento hasta febrero de 2026, validación de marzo a mayo y prueba de junio a agosto de 2026); los modelos se evalúan sobre los meses más recientes, fuera de muestra, sin fuga de información.

Criterio de despliegue: un candidato reemplaza al modelo base solo si lo supera en MLflow de forma reproducible, con la misma semilla, las mismas fechas de corte y la misma versión de datos.

MAKING PREDICTIONS

Modalidad y frecuencia: por lotes programados; una vez al día para P1, cada 3 horas para P2 y de forma mensual o trimestral para P3.

Tiempo disponible: menos de 5 minutos para construir las variables con features.py y generar las predicciones, lo que deja al equipo de rebalanceo casi todo el intervalo para operar en calle.

Recursos: una computadora local con Python, pandas y scikit-learn leyendo desde Parquet; sin cómputo distribuido ni servicio en línea.

BUILDING MODELS

Modelos necesarios: tres flujos independientes (regresión, clasificación y clustering), cada uno con un modelo base y al menos un candidato registrados en el experimento mibici-equipo10 de MLflow.

Actualización: reentrenamiento mensual, al publicarse un archivo nuevo de viajes, o ante un cambio de estación del año.

Tiempo y recursos: procesamiento fuera de línea, de minutos a unas pocas horas en una computadora local, leyendo millones de registros desde Parquet.

FEATURES

Al momento de predecir: en P1 y P2, hora o intervalo del día, día de la semana, indicador de fin de semana, capacidad de la estación y comportamiento pasado de la estación (salidas, llegadas y desbalance de hace 1 hora, 24 horas y 7 días, más promedios móviles recientes). En P3, porcentaje de movimientos por periodo del día, porcentaje en días laborales, uso diario por anclaje y balances de la mañana y de la tarde.

Transformaciones: limpieza, unión con el catálogo de estaciones y agregación por estación y ventana de tiempo usando únicamente datos anteriores al momento de la predicción.

MONITORING

Métricas técnicas (MLflow): MAE y RMSE en P1; sensibilidad y precisión de las clases vaciarse y llenarse, F1 macro y matriz de confusión en P2; coeficiente de silueta e índice de Davies-Bouldin en P3, siempre con el conjunto como prefijo (test_mae, test_recall_vaciarse, train_silhouette).

Indicadores de negocio: porcentaje de intervalos con estaciones vacías o llenas y kilómetros recorridos por las camionetas de rebalanceo por bicicleta movida.

Revisión: semanal para las predicciones operativas (P1 y P2) y mensual para la agrupación de estaciones (P3). Un deterioro sostenido de las métricas dispara el reentrenamiento.