MACHINE LEARNING CANVAS

Designed for: Sistema MiBici | Designed by: Equipo 10 - TC5061 | Date: 18/10/2026 | Iteration: 1.0

PREDICTION TASK

Tarea: Regresión (P1), Clasificación binaria (P2) y Clustering (P3).

Entidad: Cada estación por hora (P1 y P2) y cada estación consolidada (P3).

Resultado: Total de viajes iniciados (P1); alerta "En riesgo" o "Sin riesgo" cuando el desbalance neto entre llegadas y salidas iguala o supera el 40% de la capacidad de la estación (P2), grupo funcional de uso (P3).

Observación: Al cierre de cada hora en P1 y P2, análisis histórico sin etiqueta en P3.

DECISIONS

Acciones: En P1, definir la flota activa diaria y agendar mantenimiento en horas de baja demanda. En P2, priorizar qué estaciones abastecer o vaciar y trazar rutas de camionetas de rebalanceo. En P3, elegir zonas para nuevas estaciones o más anclajes.

Parámetros: Capacidad total de anclajes por estación, límite crítico del 40% de desbalance horario, probabilidad mínima para despachar camioneta y cantidad de grupos a formar.

VALUE PROPOSITION

Beneficiarios: Operador del sistema (planea flota en P1), equipo de rebalanceo (evita estaciones vacías o llenas en P2) y planeación urbana (expande la red estratégicamente en P3). Beneficia al ciclista al asegurar disponibilidad de bicicletas y anclajes.

Integración e interfaz: Ejecución por terminal desde el repositorio del proyecto y consulta de resultados, métricas y mapas en la interfaz web de MLFlow Tracking

DATA COLLECTION

Obtención inicial: Descarga automática desde terminal (dataset.py) sin pasos manuales; limpia datos, estandariza nombres de columnas y calcula las etiquetas objetivo.

Actualización y costos: Carga mensual configurada en config.py, guardada localmente en formato Parquet y controlada con un archivo manifiesto que registra el total de viajes y la huella digital del archivo.

DATA SOURCES

Fuente: Portal de Datos Abiertos de MiBici del Área Metropolitana de Guadalajara.

IMPACT SIMULATION

Costos y beneficios: Acertar optimiza recorridos de camionetas y asegura viajes; no detectar una estación que se vacía o llena afecta gravemente al usuario; una falsa alarma solo genera un recorrido innecesario moderado.

Datos de simulación: Se utiliza una partición estrictamente temporal de los datos históricos (entrenamiento, validación y prueba en orden cronológico), evaluando los modelos sobre los meses más recientes fuera de muestra para simular el desempeño futuro sin fuga de información.

Despliegue: Superar al modelo base en MLFlow de forma reproducible, bajo las mismas semillas, fechas y versión de datos.

MAKING PREDICTIONS

Modalidad y frecuencia: Por lotes programados: cada 24 horas para P1, cada 1 a 3 horas para P2 y de forma mensual o trimestral para P3.

Tiempo disponible: Menos de 5 minutos para transformar las variables (features.py) y generar predicciones, dejando más de 50 minutos de margen por hora para operar en calle.

Recursos: Procesador estándar en computadora local ejecutando Python y scikit-learn sobre archivos Parquet

BUILDING MODELS

Modelos necesarios: 3 flujos independientes (Regresión, Clasificación y Clustering) con sus modelos base y candidatos registrados en MLFlow.

Actualización: Reentrenamiento mensual al publicarse un nuevo archivo de viajes o ante cambios de estación del año.

Tiempo y recursos: Procesamiento fuera de línea de 1 a 24 horas en equipo local estándar, leyendo millones de registros desde Parquet

FEATURES

Variables al predecir: En P1 y P2: hora del día, día de la semana, indicador de fin de semana, capacidad de la estación y comportamiento pasado (viajes y desbalance de hace 1 hora, 24 horas y 1 semana, más promedios recientes). En P3: porcentaje de viajes por turno del día, uso en fin de semana, rotación por anclaje y balance entre salidas y llegadas.

Transformaciones: Limpieza, unión con catálogo de estaciones y conteo por hora usando solo datos previos al momento de predecir

MONITORING

Métricas técnicas (MLFlow): Error absoluto medio y raíz del error cuadrático medio en P1; medida F1, sensibilidad (recall) y área bajo la curva de precisión-sensibilidad en P2; coeficiente de silueta e índice Davies-Bouldin en P3.

Indicadores de negocio: Porcentaje de horas con estaciones vacías o llenas y eficiencia de rutas de rebalanceo.

Revisión: Semanal para predicciones operativas (P1 y P2) y mensual para agrupación de estaciones (P3).